RAG Customer Service Bot

Lumina Attire | Dokumentasi proyek

Ringkasan. Otomatisasi customer service berbasis retrieval, dengan jalur eskalasi manusia dan fallback saat AI Agent mengalami error.

Stack: n8n, Google Gemini 2.5 Flash, Supabase Vector Store, WAHA, Telegram. Status: workflow nonaktif (`active: false`); pinned payload tersedia, execution log tidak disertakan.

1. Project Overview

Pertanyaan berulang mengenai ongkir, estimasi pengiriman, ukuran, bahan, retur, pembayaran, dan promo membutuhkan jawaban yang konsisten. Pertanyaan tentang stok belum dapat dijawab otomatis karena workflow tidak memiliki tool pengecekan stok.

Pesan masuk diterima melalui webhook WAHA, dinormalisasi, lalu divalidasi sebelum diteruskan ke AI Agent. Gemini 2.5 Flash menghasilkan jawaban dengan bantuan knowledge base SOP melalui Supabase Vector Store. Workflow memisahkan balasan normal, eskalasi pelanggan, dan fallback saat Agent mengalami error.

JSON menggunakan path webhook `instagram_dm`, tetapi payload dan endpoint yang terlihat berorientasi pada WAHA. File ini tidak membuktikan integrasi Meta/Instagram langsung. Sistem tidak memproses transaksi atau menetapkan keputusan harga/kebijakan.

2. Arsitektur Solusi

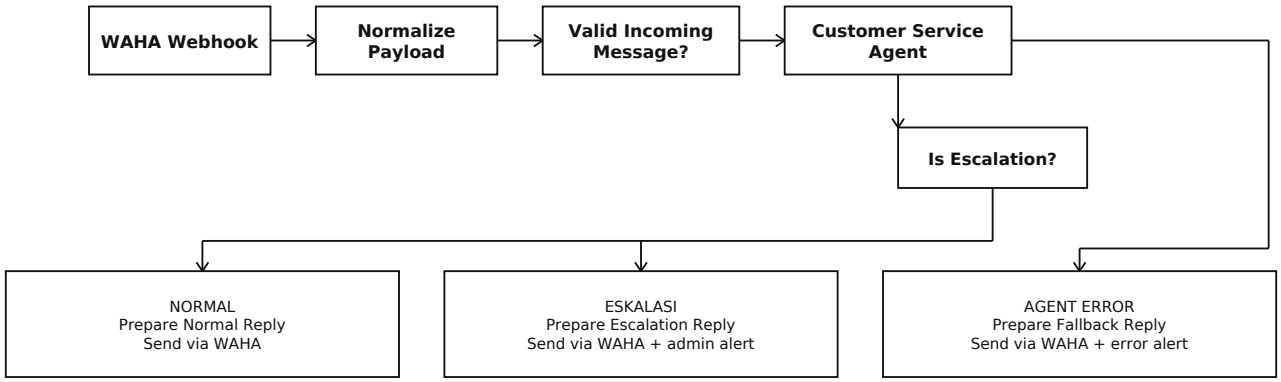

Normal/eskalasi berasal dari IF; error memakai output error Agent. Diagram merepresentasikan konfigurasi, bukan hasil runtime.

Komponen utama

Webhook dan validasi. Mengambil teks pesan, pengenal pengirim, nomor alternatif, dan `fromMe`. IF memeriksa teks, sender, dan `fromMe=false`. Namun normalisasi mengubah field `fromMe` yang hilang menjadi `false`, sehingga field yang hilang dapat lolos sebagai pesan masuk; event type juga belum divalidasi. Cabang yang ditolak belum memiliki tindak lanjut khusus.

Gemini Agent dan memory. Gemini 2.5 Flash memproses pesan dengan system prompt. Memory memakai `chatId` sebagai key dan window 16. Catatan workflow menyebut memory in-memory dan hilang ketika n8n restart.

Retrieval SOP. `search_sop` memakai Supabase Vector Store, tabel `documents`, query function `match_documents`, `topK = 6`, dan Gemini embeddings. Akurasi retrieval masih perlu diuji.

Pengiriman pesan. Jalur normal dan eskalasi mengirim balasan melalui WAHA. Jalur eskalasi diteruskan ke alert admin; jalur Agent error mengirim fallback dan alert teknis melalui Telegram.

3. Keputusan Teknis

Retrieval sebagai tool dengan instruksi penggunaan ketat

System prompt mengharuskan pemanggilan `search_sop` untuk pertanyaan kebijakan toko. Ini mengarahkan model ke sumber pengetahuan toko, tetapi tidak menjamin jawaban benar tanpa meninjau hasil retrieval dan menguji respons.

Format eskalasi eksplisit

Agent diminta menghasilkan `ESCALATE||alasan||balasan_customer`. IF memeriksa prefix tersebut dan node persiapan balasan mengambil teks setelah delimiter. Cara ini mudah ditelusuri, tetapi output yang tidak sesuai format perlu divalidasi.

Jalur normal, eskalasi, dan fallback terpisah

JSON terbaru memiliki jalur `Prepare Normal Reply`, `Prepare Escalation Reply`, dan `Prepare Fallback Reply`. Jalur eskalasi dan error menyusun alert Telegram yang berbeda. Status kirim pada alert eskalasi bergantung pada respons WAHA dan perlu diverifikasi dengan respons API aktual.

Memory per pengirim

Memory memakai custom key dari `chatId` dan context window 16. Ini memberi konteks untuk percakapan dengan key yang sama; menurut catatan workflow, memori hilang saat n8n restart.

4. Pengujian dan Bukti

JSON berisi pinned payload dengan contoh pesan “kak, baju ku robek aku mau return”. Pinned payload membuktikan tersedianya sampel input, bukan keberhasilan eksekusi. Workflow saat ini berstatus nonaktif dan execution log tidak disertakan.

Skenario	Expected result	Status berdasarkan artefak
Pesan valid	Diteruskan ke Agent ketika teks dan sender tersedia serta `fromMe=false`.	Kondisi IF dikonfigurasi; missing `fromMe` perlu diperketat; runtime belum terverifikasi.
Pertanyaan kebijakan	Agent mencari SOP yang relevan dan menjawab dari dokumen.	Tool terhubung; retrieval dan akurasi belum diuji.
Komplain / retur	Pelanggan menerima balasan; admin menerima alasan dan pesan komplain.	Jalur terpisah terlihat; hasil pengiriman belum terverifikasi.
Agent error	Pelanggan menerima fallback; admin menerima alert teknis.	Jalur dikonfigurasi; error dan hasil kirim belum terverifikasi.
Pesan kosong / dari bot	Tidak diteruskan ke Agent.	Filter ada; missing `fromMe` dapat menjadi false secara default dan event type belum dicek.

5. Keterbatasan dan Pengembangan Berikutnya

Verifikasi kredensial di environment n8n. Dalam JSON yang diunggah, referensi credential tidak tercantum pada node Supabase, HTTP Request WAHA, dan Telegram. Tautkan credential yang dibutuhkan sebelum uji runtime; jangan masukkan secret ke dokumentasi.

Tangani kegagalan pengiriman pada semua jalur. Jalur normal dan fallback WAHA belum menunjukkan penanganan error khusus. Uji timeout, HTTP error, serta respons aplikasi yang gagal. Pastikan pesan yang gagal terkirim tidak dianggap berhasil.

Validasi output eskalasi dan status kirim. `Is Escalation?` memeriksa prefix `ESCALATE`. Tambahkan validasi format sebelum parsing. Verifikasi apakah field error pada output WAHA benar-benar mencerminkan status pengiriman.

Uji RAG, memory, dan webhook. Uji pertanyaan dengan sumber SOP tersedia/tidak tersedia, konteks antar-pengirim, payload malformed, event bukan pesan masuk, dan perilaku memory setelah restart. Pertimbangkan autentikasi atau validasi sumber request sebelum penggunaan nyata.

Pengujian lanjutan: pertanyaan SOP tersedia, pertanyaan di luar knowledge base, komplain/retur, output eskalasi malformed, error Agent/Supabase/WAHA/Telegram, payload kosong, pesan dari bot sendiri, dan pemisahan konteks antar-pengirim.

Dokumen ini merangkum konfigurasi pada `RAG-CS BOT.json`. Ini bukan klaim bahwa workflow aktif atau lulus pengujian end-to-end.